

LAPORAN PROYEK UAS

Klasifikasi Pesan Spam Berbahasa Indonesia Menggunakan TF-IDF dan Naive Bayes Berbasis Streamlit



Oleh
Dian Safitri
NIM. IK2311006

PROGRAM STUDI SARJANA INFORMATIKA
FAKULTAS ILMU KOMPUTER
UNIVERSITAS MEGA BUANA PALOPO
2025

BAB I

PENDAHULUAN

1.1 Latar Belakang

Perkembangan teknologi informasi telah meningkatkan penggunaan Short Message Service (SMS) sebagai salah satu media komunikasi yang cepat dan mudah diakses. SMS digunakan untuk berbagai keperluan, seperti komunikasi pribadi, layanan perbankan, promosi produk, maupun penyampaian informasi dari berbagai instansi. Namun, kemudahan tersebut juga dimanfaatkan oleh pihak-pihak yang tidak bertanggung jawab untuk menyebarkan spam, yaitu pesan yang dikirim secara massal tanpa persetujuan penerima dan sering kali berisi promosi yang tidak diinginkan atau bahkan upaya penipuan (Almeida et al., 2011).

Pesan spam dapat mengganggu kenyamanan pengguna, menurunkan kepercayaan terhadap layanan pesan singkat, serta meningkatkan risiko kerugian akibat penipuan. Oleh karena itu, diperlukan suatu sistem yang mampu mengidentifikasi secara otomatis apakah suatu pesan termasuk kategori spam atau ham (bukan spam) sehingga pengguna dapat memperoleh informasi yang lebih aman dan akurat.

Natural Language Processing (NLP) merupakan cabang kecerdasan buatan yang mempelajari bagaimana komputer memahami, mengolah, dan menganalisis bahasa manusia. Salah satu penerapan NLP adalah klasifikasi teks, yaitu proses mengelompokkan dokumen berdasarkan isi atau maknanya (Jurafsky & Martin, 2025). Dalam proyek ini digunakan metode Term Frequency–Inverse Document Frequency (TF-IDF) sebagai representasi teks dan algoritma Multinomial Naive Bayes sebagai model klasifikasi karena memiliki performa yang baik pada data berbentuk teks (Manning et al., 2008).

Hasil klasifikasi kemudian diimplementasikan dalam sebuah aplikasi berbasis Streamlit sehingga pengguna dapat melakukan prediksi secara langsung melalui antarmuka web yang sederhana dan mudah digunakan.

1.2 Identifikasi Masalah

Berdasarkan latar belakang tersebut, dapat diidentifikasi beberapa permasalahan sebagai berikut.

1. Banyaknya pesan spam yang diterima pengguna.
2. Sulitnya membedakan pesan spam dan pesan normal secara cepat.
3. Dibutuhkan sistem klasifikasi otomatis yang memiliki akurasi tinggi.

1.3 Rumusan Masalah

Rumusan masalah dalam proyek ini adalah sebagai berikut.

1. Bagaimana membangun model klasifikasi SMS spam menggunakan NLP?
2. Bagaimana menerapkan TF-IDF pada data SMS?
3. Bagaimana mengimplementasikan Multinomial Naive Bayes untuk klasifikasi spam?
4. Bagaimana membangun aplikasi berbasis Streamlit untuk melakukan prediksi pesan SMS?

1.4 Tujuan Proyek

Tujuan yang ingin dicapai dalam proyek ini adalah sebagai berikut.

1. Mengembangkan sistem klasifikasi SMS spam menggunakan Natural Language Processing.
2. Menerapkan metode TF-IDF sebagai representasi teks.
3. Mengimplementasikan algoritma Multinomial Naive Bayes dalam proses klasifikasi.
4. Mengembangkan aplikasi berbasis Streamlit sebagai antarmuka pengguna.
5. Mengevaluasi performa model menggunakan accuracy, precision, recall, F1-score, dan confusion matrix.

BAB II

LANDASAN TEORI

2.1 Natural Language Processing (NLP)

Natural Language Processing (NLP) merupakan salah satu cabang dari kecerdasan buatan (*Artificial Intelligence*) yang berfokus pada pengolahan dan pemahaman bahasa alami agar dapat diproses oleh komputer. NLP menggabungkan konsep linguistik, ilmu komputer, dan pembelajaran mesin untuk memungkinkan sistem memahami makna dari teks atau bahasa manusia (Jurafsky & Martin, 2025).

Dalam perkembangannya, NLP telah banyak diterapkan pada berbagai bidang, seperti analisis sentimen, penerjemahan bahasa, chatbot, klasifikasi dokumen, deteksi spam, hingga sistem pencarian informasi. Pada proyek ini, NLP digunakan untuk mengklasifikasikan pesan SMS ke dalam dua kategori, yaitu spam dan ham (bukan spam) berdasarkan isi teks yang dimasukkan oleh pengguna.

2.2 Text Preprocessing

Text preprocessing merupakan tahap awal dalam pengolahan data teks yang bertujuan untuk membersihkan dan menyiapkan data sebelum diproses oleh algoritma machine learning. Tahap ini penting karena data teks umumnya masih mengandung karakter yang tidak diperlukan sehingga dapat memengaruhi kinerja model (Manning et al., 2008).

Pada proyek ini dilakukan beberapa tahapan preprocessing, yaitu:

- a. Case Folding, yaitu mengubah seluruh huruf menjadi huruf kecil (*lowercase*).
- b. Cleaning, yaitu menghapus karakter khusus, angka, tanda baca, dan simbol yang tidak diperlukan.
- c. Tokenizing, yaitu memecah kalimat menjadi kumpulan kata.
- d. Stopword Removal, yaitu menghapus kata-kata umum yang tidak memiliki makna penting, seperti *dan*, *yang*, *di*, dan *ke*.
- e. Stemming, yaitu mengubah kata menjadi bentuk dasarnya menggunakan algoritma stemming Bahasa Indonesia.

Hasil preprocessing berupa teks yang lebih bersih sehingga dapat meningkatkan kualitas representasi fitur dan akurasi klasifikasi.

2.3 Representasi Teks (TF-IDF)

Komputer tidak dapat memahami teks secara langsung sehingga diperlukan proses representasi teks menjadi bentuk numerik. Salah satu metode yang paling banyak digunakan adalah Term Frequency–Inverse Document Frequency (TF-IDF).

TF-IDF memberikan bobot pada setiap kata berdasarkan dua komponen utama, yaitu:

1. Term Frequency (TF), yang menunjukkan seberapa sering suatu kata muncul dalam sebuah dokumen.
2. Inverse Document Frequency (IDF), yang mengurangi bobot kata-kata yang terlalu sering muncul pada seluruh dokumen.

Kombinasi kedua komponen tersebut menghasilkan representasi numerik yang mampu menunjukkan tingkat kepentingan suatu kata dalam dokumen. Pada penelitian ini, hasil TF-IDF digunakan sebagai masukan (*input feature*) bagi algoritma Multinomial Naive Bayes (Ramos, 2003).

2.4 Algoritma Multinomial Naive Bayes

Multinomial Naive Bayes merupakan salah satu algoritma klasifikasi yang menggunakan pendekatan probabilitas berdasarkan Teorema Bayes. Algoritma ini mengasumsikan bahwa setiap fitur bersifat independen terhadap fitur lainnya sehingga proses perhitungan menjadi lebih sederhana (Zhang, 2004).

Multinomial Naive Bayes banyak digunakan pada klasifikasi dokumen karena mampu menangani data berbentuk frekuensi kata secara efektif. Pada proyek ini, algoritma digunakan untuk menghitung probabilitas apakah suatu pesan SMS termasuk kategori spam atau ham berdasarkan hasil representasi TF-IDF.

Keunggulan algoritma ini antara lain:

- a. Proses pelatihan relatif cepat.
- b. Efisien pada data teks berdimensi tinggi.
- c. Mudah diimplementasikan.
- d. Memiliki performa yang baik untuk klasifikasi dokumen.

2.5 Metrik Evaluasi

Untuk mengetahui performa model klasifikasi digunakan beberapa metrik evaluasi yang berasal dari Confusion Matrix.

1. Accuracy

Accuracy merupakan persentase prediksi yang benar dibandingkan dengan seluruh data pengujian.

Pada proyek ini diperoleh nilai accuracy sebesar 98,25%, yang menunjukkan bahwa model mampu mengklasifikasikan sebagian besar data dengan benar.

2. Precision

Precision menunjukkan tingkat ketepatan model dalam memprediksi kelas positif (spam).

Semakin tinggi nilai precision maka semakin sedikit pesan normal yang salah diklasifikasikan sebagai spam.

3. Recall

Recall menunjukkan kemampuan model dalam menemukan seluruh data spam yang sebenarnya. Nilai recall yang tinggi menunjukkan bahwa sebagian besar pesan spam berhasil dideteksi oleh sistem.

4. F1-Score

F1-Score merupakan rata-rata harmonik antara precision dan recall sehingga memberikan gambaran performa model secara keseluruhan.

5. Confusion Matrix

Confusion Matrix merupakan tabel yang menggambarkan jumlah prediksi benar maupun prediksi salah dari setiap kelas.

Berdasarkan hasil pengujian proyek ini diperoleh confusion matrix sebagai berikut.

Aktual	Prediksi Ham	Prediksi Spam
Ham	111	3
Spam	1	114

Hasil tersebut menunjukkan bahwa model hanya melakukan empat kesalahan klasifikasi dari total 229 data pengujian sehingga menghasilkan performa yang sangat baik.

2.6 Teknologi Pendukung

Beberapa teknologi yang digunakan dalam pengembangan proyek ini adalah sebagai berikut.

A Python

Python digunakan sebagai bahasa pemrograman utama karena memiliki banyak pustaka untuk pengolahan data, machine learning, dan pengembangan aplikasi.

B Google Colab

Google Colab digunakan sebagai lingkungan pengembangan untuk proses preprocessing data, pelatihan model, dan evaluasi karena menyediakan lingkungan Python berbasis cloud tanpa memerlukan instalasi tambahan.

C Scikit-learn

Scikit-learn merupakan pustaka machine learning yang digunakan untuk proses pembagian dataset (*train-test split*), ekstraksi fitur TF-IDF, pelatihan model Multinomial Naive Bayes, serta evaluasi model.

D Streamlit

Streamlit digunakan untuk membangun antarmuka aplikasi berbasis web sehingga pengguna dapat melakukan prediksi SMS spam secara interaktif tanpa harus menjalankan kode Python secara langsung.

E Joblib

Joblib digunakan untuk menyimpan (*serialization*) model hasil pelatihan (`spam_model.pkl`) dan objek TF-IDF (`tfidf_vectorizer.pkl`) sehingga model dapat digunakan kembali pada aplikasi Streamlit tanpa perlu melakukan proses pelatihan ulang.

F Visual Studio Code

Visual Studio Code digunakan sebagai *Integrated Development Environment (IDE)* untuk mengembangkan, mengedit, dan menjalankan aplikasi Streamlit.

BAB III

METODE PENGEMBANGAN

3.1 Tahapan Pengembangan

Pengembangan proyek ini dilakukan secara bertahap mulai dari Tahapan pengembangan:



3.2 Sumber dan Deskripsi Dataset

Dataset yang digunakan pada proyek ini merupakan dataset SMS Spam Bahasa Indonesia yang berisi kumpulan pesan singkat yang telah diberi label menjadi dua kategori, yaitu Spam dan Ham (bukan spam).

Dataset memiliki dua atribut utama, yaitu:

No	Nama Kolom	Deskripsi
1	text	Isi pesan SMS
2	label	Kategori pesan (Spam atau Ham)

Jumlah keseluruhan data yang digunakan sebanyak 1.143 data, yang terdiri atas:

Kategori	Jumlah
Spam	574
Ham	569
Total	1.143

Dataset memiliki distribusi kelas yang relatif seimbang sehingga cocok digunakan untuk proses pelatihan model klasifikasi.

3.3 Analisis Data

Tahap analisis data dilakukan untuk memahami karakteristik dataset sebelum proses pelatihan model.

Hasil analisis menunjukkan bahwa:

- Dataset terdiri atas dua kelas, yaitu spam dan ham.
- Data berbentuk teks sehingga memerlukan preprocessing.
- Sebagian besar pesan spam berisi promosi, hadiah, pinjaman, atau tautan tertentu.
- Pesan ham umumnya berisi percakapan sehari-hari.

Contoh data ditunjukkan pada Tabel 3.3.

Label	Pesan
Spam	Selamat! Anda memenangkan hadiah Rp100 juta.
Ham	Halo, nanti sore kita bertemu di kampus.

3.4 Preprocessing

Preprocessing dilakukan untuk meningkatkan kualitas data sebelum diproses oleh algoritma machine learning.

Tahapan preprocessing yang diterapkan meliputi:

1. Case Folding

Mengubah seluruh huruf menjadi huruf kecil.

2. Cleaning

Menghapus angka, tanda baca, URL, simbol, dan karakter yang tidak diperlukan.

3. Tokenizing

Memisahkan kalimat menjadi kumpulan kata.

4. Stopword Removal

Menghapus kata yang tidak memiliki informasi penting.

5. Stemming

Mengubah kata menjadi bentuk dasar.

Setelah preprocessing selesai, data diubah menjadi representasi numerik menggunakan metode TF-IDF.

3.5 Pembagian Dataset

Dataset dibagi menjadi dua bagian menggunakan fungsi `train_test_split()` dari Scikit-learn.

Pembagian dilakukan dengan komposisi:

Dataset	Persentase
Training	80%
Testing	20%

Dengan pembagian tersebut diperoleh:

Dataset	Jumlah
Training	914
Testing	229

Data training digunakan untuk melatih model, sedangkan data testing digunakan untuk mengevaluasi performa model.

3.6 Arsitektur Model



Model yang telah selesai dilatih kemudian disimpan menggunakan library Joblib dalam bentuk:

spam_model.pkl

tfidf_vectorizer.pkl

Penyimpanan model bertujuan agar proses prediksi pada aplikasi Streamlit dapat dilakukan tanpa perlu melatih model kembali.

3.7 Arsitektur Aplikasi

Aplikasi dikembangkan menggunakan framework Streamlit dengan struktur sederhana yang terdiri atas beberapa komponen utama.

a. Halaman Utama

Menampilkan informasi mengenai aplikasi dan petunjuk penggunaan.

b. Input Pesan

Pengguna memasukkan teks SMS yang ingin diklasifikasikan.

c. Prediksi

Aplikasi memuat model hasil pelatihan kemudian melakukan proses klasifikasi.

d. Output

Hasil klasifikasi ditampilkan dalam bentuk:

- Spam
- Ham
- Nilai confidence

3.8 Skenario Pengujian

Pengujian dilakukan dengan memasukkan beberapa contoh pesan ke dalam aplikasi Streamlit.

Contoh skenario pengujian:

No	Input	Hasil yang Diharapkan
1	Selamat! Anda memenangkan hadiah.	Spam
2	Besok kuliah jam 8 pagi.	Ham
3	Klik link berikut untuk mendapatkan bonus.	Spam
4	Jangan lupa membawa laptop.	Ham

Keberhasilan pengujian ditentukan apabila hasil prediksi sesuai dengan label sebenarnya.

BAB IV

HASIL DAN PEMBAHASAN

4.1 Hasil Preprocessing

Tahap preprocessing dilakukan untuk membersihkan data teks agar lebih mudah diproses oleh algoritma klasifikasi. Tahapan yang diterapkan meliputi case folding, cleaning, tokenizing, stopwords removal, dan stemming.

Contoh hasil preprocessing ditunjukkan pada Tabel 4.1.

Tabel 4.1 Contoh Hasil Preprocessing

Teks Asli	Hasil Preprocessing
Selamat!! Anda memenangkan hadiah Rp100 juta. Klik link berikut.	selamat menang hadiah klik link
Halo Dian, besok kuliah dimulai pukul 08.00 pagi.	halo dian besok kuliah mulai pagi
Teks Asli	Hasil Preprocessing

Tahapan preprocessing membantu mengurangi kata-kata yang tidak memiliki makna penting sehingga representasi teks menjadi lebih efektif untuk proses klasifikasi.

4.2 Hasil Pelatihan Model

Setelah preprocessing selesai, data diubah menjadi representasi numerik menggunakan metode TF-IDF. Selanjutnya, data latih digunakan untuk membangun model klasifikasi menggunakan algoritma Multinomial Naive Bayes.

Model yang telah dilatih kemudian disimpan menggunakan library Joblib dalam bentuk file:

spam_model.pkl

tfidf_vectorizer.pkl

Penyimpanan model bertujuan agar model dapat digunakan kembali pada aplikasi Streamlit tanpa harus melakukan proses pelatihan ulang setiap kali aplikasi dijalankan.

4.3 Hasil Evaluasi

Evaluasi model dilakukan menggunakan data uji sebanyak 229 data. Berdasarkan hasil pengujian diperoleh nilai evaluasi sebagai berikut.

Tabel 4.2 Hasil Evaluasi Model

Metrik	Nilai
Accuracy	98,25%
Precision	98%
Recall	98%

Nilai accuracy sebesar 98,25% menunjukkan bahwa model mampu mengklasifikasikan sebagian besar data uji dengan benar. Nilai precision, recall, dan F1-score yang sama-sama tinggi menunjukkan bahwa model memiliki keseimbangan yang baik dalam mendeteksi pesan spam maupun pesan ham.

4.4 Confusion Matrix

Hasil confusion matrix yang diperoleh adalah sebagai berikut.

Tabel 4.3 Confusion Matrix

Aktual	Prediksi Ham	Prediksi Spam
Ham	111	3
Spam	1	114

Berdasarkan confusion matrix tersebut dapat dijelaskan bahwa:

- Sebanyak 111 pesan ham berhasil diprediksi dengan benar.
- Sebanyak 114 pesan spam berhasil diprediksi dengan benar.
- Terdapat 3 pesan ham yang salah diklasifikasikan sebagai spam (*false positive*).
- Terdapat 1 pesan spam yang salah diklasifikasikan sebagai ham (*false negative*).

Jumlah kesalahan klasifikasi yang relatif sedikit menunjukkan bahwa model memiliki kemampuan yang sangat baik dalam membedakan pesan spam dan pesan bukan spam.

4.5 Tampilan Aplikasi

Aplikasi dikembangkan menggunakan framework Streamlit sehingga dapat diakses melalui web browser secara lokal.

Fitur utama aplikasi meliputi:

- Halaman utama aplikasi.
- Form input pesan SMS.
- Tombol prediksi.
- Hasil klasifikasi Spam atau Ham.
- Nilai confidence hasil prediksi.

4.6 Hasil Pengujian Aplikasi

Pengujian dilakukan dengan memasukkan beberapa contoh pesan ke dalam aplikasi. Hasil pengujian ditunjukkan pada Tabel 4.4.

Tabel 4.4 Hasil Pengujian Aplikasi

No	Input Pesan	Hasil Sistem	Status
1	Selamat! Anda memenangkan hadiah Rp100 juta.	Spam	Sesuai

2	Besok kuliah dimulai pukul 08.00 pagi.	Ham	Sesuai
3	Klik link berikut untuk mendapatkan bonus.	Spam	Sesuai
4	Jangan lupa membawa laptop.	Ham	Sesuai

Hasil pengujian menunjukkan bahwa aplikasi mampu melakukan klasifikasi sesuai dengan label yang diharapkan pada contoh pengujian yang digunakan.

4.7 Analisis Kesalahan Model

Meskipun model memiliki tingkat akurasi yang tinggi, masih terdapat beberapa kesalahan klasifikasi. Kesalahan tersebut umumnya terjadi pada pesan yang memiliki karakteristik menyerupai kedua kelas.

Sebagai contoh, pesan promosi yang menggunakan bahasa formal atau pesan pribadi yang mengandung kata-kata promosi tertentu dapat menyebabkan model memberikan prediksi yang kurang tepat. Hal ini disebabkan karena model hanya memanfaatkan informasi berdasarkan frekuensi kata tanpa memahami konteks kalimat secara menyeluruh. Selain itu, kualitas dan keberagaman dataset juga memengaruhi kemampuan model dalam melakukan generalisasi terhadap data baru.

4.8 Perbandingan Hasil

Performa model yang dikembangkan pada proyek ini dibandingkan dengan beberapa penelitian terdahulu yang menggunakan algoritma Naive Bayes untuk klasifikasi spam.

Tabel 4.5 Perbandingan Hasil Penelitian

Penelitian	Metode	Accuracy
Almeida et al. (2011)	Naive Bayes	97,60%
Penelitian lain (contoh)	TF-IDF + Naive Bayes	96–98%
Proyek ini	TF-IDF + Multinomial Naive Bayes	98,25%

Berdasarkan hasil tersebut, model yang dikembangkan memiliki performa yang kompetitif dan mampu memberikan hasil klasifikasi yang baik pada dataset SMS Spam Bahasa Indonesia.

4.9 Pembahasan Bias, Privasi, dan Etika

a. Bias

Model dibangun berdasarkan dataset yang digunakan selama proses pelatihan. Apabila dataset kurang beragam atau tidak mewakili berbagai jenis pesan SMS, model dapat mengalami bias, yaitu cenderung lebih baik dalam mengenali pola tertentu dibandingkan pola lainnya. Untuk mengurangi bias, diperlukan dataset yang lebih besar dan bervariasi.

b. Privasi

Data SMS dapat mengandung informasi pribadi pengguna, seperti nama, nomor telepon, atau isi percakapan. Oleh karena itu, penggunaan data harus memperhatikan aspek privasi dengan menghindari penyebaran informasi sensitif dan hanya menggunakan data untuk tujuan penelitian atau pengembangan sistem sesuai ketentuan yang berlaku.

c. Etika

Pengembangan sistem klasifikasi spam harus dilakukan secara bertanggung jawab. Hasil prediksi dari sistem sebaiknya digunakan sebagai alat bantu dalam pengambilan keputusan, bukan sebagai satu-satunya dasar untuk menentukan apakah suatu pesan merupakan spam. Selain itu, pengembang perlu menjaga transparansi mengenai cara kerja sistem dan terus melakukan evaluasi agar model tetap memberikan hasil yang adil dan akurat.

BAB V

PENUTUP

5.1 Kesimpulan

Berdasarkan hasil pengembangan dan pengujian yang telah dilakukan, dapat disimpulkan bahwa proyek Deteksi Spam SMS Bahasa Indonesia Menggunakan TF-IDF dan Multinomial Naive Bayes Berbasis Streamlit telah berhasil diimplementasikan sesuai dengan tujuan yang ditetapkan.

Metode TF-IDF mampu mengubah data teks menjadi representasi numerik yang dapat diproses oleh algoritma Multinomial Naive Bayes. Berdasarkan hasil evaluasi, model memperoleh accuracy sebesar 98,25%, dengan nilai precision, recall, dan F1-score yang sama-sama mencapai 98%. Hasil tersebut menunjukkan bahwa model mampu mengklasifikasikan pesan SMS ke dalam kategori spam dan ham dengan tingkat ketepatan yang tinggi.

Selain itu, model yang telah dilatih berhasil diimplementasikan ke dalam aplikasi berbasis Streamlit, sehingga pengguna dapat melakukan klasifikasi pesan SMS secara mudah melalui antarmuka web yang sederhana dan interaktif.

5.2 Keterbatasan

Meskipun model memiliki performa yang baik, proyek ini masih memiliki beberapa keterbatasan, yaitu:

1. Dataset yang digunakan masih terbatas sehingga belum mencakup seluruh variasi bahasa yang digunakan pada SMS di dunia nyata.
2. Model hanya mampu mengklasifikasikan dua kategori, yaitu spam dan ham.
3. Sistem hanya memproses teks berbahasa Indonesia.
4. Model menggunakan algoritma Multinomial Naive Bayes yang belum mempertimbangkan hubungan antar kata secara mendalam.
5. Aplikasi masih berjalan secara lokal menggunakan Streamlit dan belum diimplementasikan pada server publik.

5.3 Saran Pengembangan

1. Menambah jumlah dan variasi dataset agar model memiliki kemampuan generalisasi yang lebih baik.
2. Membandingkan performa algoritma lain, seperti Support Vector Machine (SVM), Random Forest, atau model berbasis Transformer seperti IndoBERT.
3. Menambahkan fitur visualisasi statistik hasil prediksi pada aplikasi.
4. Mengembangkan aplikasi agar dapat diakses secara daring (*online deployment*).
5. Menambahkan fitur penyimpanan riwayat prediksi menggunakan basis data sehingga hasil klasifikasi dapat disimpan dan dianalisis lebih lanjut.